

SATRANÇTAŞI SINIFLANDIRMA PROJESİ

Yapay Zeka Temelleri Dersi — Vize & Final Raporu

Kullanılan Yöntem:

Transfer Learning — MobileNetV2 (CNN)

Veri Seti:

Kaggle Chess Pieces — 6 Sınıf, ~2000 Görüntü

Model Doğruluğu:

%85.53 Test Doğruluğu

1. Problem Tanımı

Bu projenin amacı, bilgisayarlı görü (computer vision) ve derin öğrenme tekniklerini kullanarak farklı satranç taşlarını (Şah, Vezir, Kale, Fil, At, Piyon) dijital görüntüler üzerinden otomatik olarak sınıflandırmaktır.

Proje, makine öğrenmesi sürecinin uçtan uca deneyimlenmesini hedeflemektedir. Bu kapsamda veri toplama, EDA (Keşifsel Veri Analizi), ön işleme, model kurma ve model değerlendirme aşamalarının tamamı gerçekleştirilmiştir.

2. Veri Setinin Tanıtımı

- **Kaynak:** Kaggle Chess Pieces
- **Bağlantı:** <https://www.kaggle.com/datasets/khiredinebenmeziane/chess-pieces>
- **Sınıf Sayısı:** 6 farklı sınıf — Rook (Kale), Queen (Vezir), Pawn (Piyon), Knight (At), King (Şah), Bishop (Fil)
- **Veri Miktarı:** Yaklaşık 2000 adet görüntü
- **Veri Yapısı:** Görüntüler farklı çözünürlüklerde (örn: 172x293, 224x224) ve farklı renk modlarındadır (RGB ve P modu)

3. Keşifsel Veri Analizi (EDA) ve Görselleştirme

3.1 Sınıf Dağılımı

Veri setindeki her sınıfa ait görüntü sayısı bar grafik ile görselleştirilmiştir. Sınıfların dengeli dağılımı, modelin belirli bir sınıfa karşı önyargılı (bias) olmasını engellemek açısından kritik öneme sahiptir.

3.2 Eksik / Bozuk Veri Kontrolü

`df.isnull()` analizi ile veri setinde okunmayan veya hatalı dosya bulunup bulunmadığı kontrol edilmiştir. Analiz sonucunda veri setinde eksik ya da bozuk dosya tespit edilmemiştir.

3.3 Örnek Görüntüler ve Piksel Dağılımı

Her sınıftan birer örnek görüntü görselleştirilmiş; ham piksel değerlerinin (0–255) ve normalize edilmiş değerlerin (0–1) dağılımı histogram ile karşılaştırmalı olarak gösterilmiştir.

4. Veri Ön İşleme (Preprocessing)

Model eğitimi öncesinde tüm veriler aşağıdaki adımlardan geçirilmiştir:

- **Yeniden Boyutlandırma (Resizing):** Tüm görseller MobileNetV2 modelinin giriş katmanı ile uyumlu olması için 224×224 piksel boyutuna sabitlenmiştir.
- **Normalizasyon:** 0–255 arasındaki piksel değerleri $x_{norm} = x / 255$ formülü ile [0, 1] aralığına çekilmiştir. Bu işlem modelin eğitim hızını (convergence) artırmak için uygulanmıştır.
- **Renk Modu Standardizasyonu:** Tüm görüntüler RGB formatına dönüştürülmüştür. Bu sayede farklı modlardaki (P, RGBA) görseller tutarlı hale getirilmiştir.
- **Veri Bölme:** Veri seti %80 Eğitim (1574 resim) ve %20 Test (394 resim) olarak ayrılmıştır. Stratify parametresi ile sınıf dengesi korunmuştur.

5. Model Kurma

5.1 Algoritma Seçimi: Transfer Learning ile MobileNetV2 (CNN)

Görüntü sınıflandırması için Evrimsel Sinir Ağı (CNN) tabanlı Transfer Learning yöntemi kullanılmıştır. Seçilen model MobileNetV2'dir.

MobileNetV2'nin tercih edilme nedenleri:

- ImageNet veri seti üzerinde milyonlarca görüntüyle önceden eğitilmiş; kenarlar, dokular ve şekiller gibi temel görsel özellikleri zaten öğrenmiştir.
- ~2000 görüntüden oluşan küçük veri setlerinde sıfırdan eğitim yerine Transfer Learning kullanmak çok daha yüksek doğruluk sağlar.
- Hafif mimarisi sayesinde eğitim süresi makul seviyede kalmaktadır.

5.2 Model Mimarisi

Modelin katman yapısı aşağıdaki gibi tasarlanmıştır:

- **Giriş Katmanı:** MobileNetV2 (ImageNet ağırlıkları, include_top=False, input_shape=224×224×3)
- **Global Average Pooling:** Özellik haritasını tek bir vektöre indirger
- **Batch Normalization:** Eğitimi kararlı hale getirir
- **Dense (256, ReLU):** Birinci tam bağlantılı katman
- **Dropout (0.4):** Aşırı öğrenmeyi (overfitting) önler
- **Dense (128, ReLU):** İkinci tam bağlantılı katman
- **Dropout (0.3):** Aşırı öğrenmeyi önler
- **Dense (6, Softmax):** 6 sınıf için çıkış katmanı

5.3 Veri Artırma (Data Augmentation)

Aşırı öğrenmeyi önlemek ve modelin farklı açı, konum ve ölçeklerdeki görüntülere genellenebilmesini sağlamak amacıyla ImageDataGenerator ile aşağıdaki dönüşümler uygulanmıştır:

- Rotation ($\pm 20^\circ$): Görüntüyü rastgele döndürme
- Width / Height Shift ($\pm 10\%$): Yatay ve dikey kaydırma
- Zoom ($\pm 10\%$): Yakınlaştırma / uzaklaştırma
- Horizontal Flip: Yatay aynalama

5.4 İki Aşamalı Eğitim Stratejisi

Model eğitimi iki aşamada gerçekleştirilmiştir:

- **Aşama 1 — Feature Extraction:** MobileNetV2 katmanları dondurulmuş, yalnızca eklenen üst katmanlar eğitilmiştir. Öğrenme oranı: $1e-3$. Bu aşamada model, satranç taşlarına özgü üst düzey özellikleri öğrenmiştir.
- **Aşama 2 — Fine-Tuning:** MobileNetV2'nin son 30 katmanı çözülerek çok düşük öğrenme oranıyla ($1e-5$) yeniden eğitilmiştir. Bu aşama, modelin veri setine daha iyi uyum sağlamasını sağlamıştır.

5.5 Eğitim Optimizasyonu — Callback'ler

- **EarlyStopping:** Validation loss 5 epoch boyunca iyileşmezse eğitimi durdurur ve en iyi ağırlıkları geri yükler
- **ModelCheckpoint:** En yüksek validation accuracy'ye sahip model otomatik olarak kaydedilir
- **ReduceLROnPlateau:** Platoya girildiğinde öğrenme oranı 0.3 katsayısıyla küçültülür

6. Model Değerlendirme

6.1 Genel Performans Metrikleri

Model, %20'lik test seti (394 görüntü) üzerinde değerlendirilmiştir. Tüm metrikler ağırlıklı ortalama (weighted average) ile hesaplanmıştır:

Metrik	Açıklama	Değer	Yüzde
Accuracy	Genel doğru tahmin oranı	0.8553	%85.53
Precision	Tahminlerin ne kadarı doğru	0.8573	%85.73
Recall	Gerçeklerin ne kadarı bulundu	0.8553	%85.53
F1 Score	Precision ve Recall ortalaması	0.8551	%85.51

Model, 2000 görüntüden oluşan küçük bir veri setiyle %85.53 test doğruluğuna ulaşmıştır. Bu sonuç, Transfer Learning yönteminin küçük veri setlerindeki etkinliğini açıkça ortaya koymaktadır.

6.2 Sınıf Bazlı Performans Analizi

Her satranç taşı sınıfı için ayrı ayrı hesaplanan metrikler aşağıdaki tabloda sunulmaktadır:

Sınıf (Taş)	Precision	Recall	F1 Score	Doğruluk
Knight (At)	%96.8	%95.7	%96.2	Çok İyi
Rook (Kale)	%90.1	%91.4	%90.7	Çok İyi
King (Şah)	%87.5	%86.9	%87.2	İyi
Pawn (Piyon)	%84.3	%84.7	%84.5	İyi
Queen (Vezir)	%72.7	%71.1	%71.9	Orta
Bishop (Fil)	%74.6	%73.8	%74.2	Orta

6.3 Confusion Matrix Analizi

Confusion matrix analizi, modelin hangi sınıfları başarıyla ayırt edebildiğini ve hangi sınıflar arasında karışıklık yaşandığını göstermektedir:

- **Knight (At):** %95.7 doğrulukla en iyi tanınan taştır. At'ın benzersiz L şekli sayesinde diğer taşlardan kolayca ayrılmaktadır.
- **Rook (Kale):** %91.4 doğruluk. Kule şeklinin belirginliği yüksek doğruluk sağlamaktadır.
- **King (Şah):** %86.9 doğruluk. Taç şekli ayırt edici olmakla birlikte Queen ile zaman zaman karışmaktadır.
- **Pawn (Piyon):** %84.7 doğruluk. Küçük ve yuvarlak formu genel olarak iyi tanınmaktadır.
- **Queen (Vezir):** %71.1 doğruluk. Bishop ile %17.8 oranında karışmaktadır. Bu iki taşın benzer silüetleri temel sorundur.
- **Bishop (Fil):** %73.8 doğruluk. Queen ile %10.8 oranında karışmaktadır.

Queen ve Bishop sınıflarındaki karışıklığın başlıca nedeni, bu taşların veri setinde stilize (soyut, çizgi film tarzı) görüntülere sahip olmasıdır. Gerçek satranç taşı fotoğrafları yerine çeşitli çizim stillerinin kullanılması modeli zorlamaktadır.

6.4 Eğitim Süreci Grafiği

Eğitim sürecinde hem Feature Extraction hem de Fine-Tuning aşamalarında accuracy ve loss değerleri izlenmiştir:

- Eğitim doğruluğu ve validation doğruluğu birlikte artmış; bu durum overfitting olmadığını göstermektedir.
- Fine-Tuning başlangıcında eğitim accuracy'sinde geçici bir düşüş gözlemlenmiştir. Bu normaldir; çok düşük öğrenme oranı nedeniyle model yeniden adapte olmaktadır.
- EarlyStopping mekanizması, validation loss platoya ulaştığında eğitimi otomatik durdurarak en iyi model ağırlıklarını kaydetmiştir.

7. Sonuç ve Değerlendirme

Bu projede satranç taşı sınıflandırması için uçtan uca bir makine öğrenmesi süreci başarıyla tamamlanmıştır. Kaggle'dan elde edilen ~2000 görüntülük veri seti üzerinde EDA, ön işleme, model eğitimi ve değerlendirme adımları gerçekleştirilmiştir.

Transfer Learning yöntemiyle MobileNetV2 mimarisi kullanılarak %85.53 test doğruluğuna ulaşılmıştır. Bu sonuç, özellikle küçük veri setlerinde Transfer Learning'in ne denli etkili olduğunu göstermektedir.

Gelecekte model performansının artırılması için şu adımlar önerilebilir:

- Veri seti genişletilerek sınıf başına düşen örnek sayısı artırılabilir.
- Queen ve Bishop sınıfları için hedefe yönelik veri artırma stratejileri uygulanabilir.
- EfficientNetV2 veya ResNet50 gibi daha güçlü mimarilerle karşılaştırmalı analiz yapılabilir.
- Hiperparametre optimizasyonu (learning rate, dropout oranı) ile doğruluk daha da artırılabilir.

8. Proje Özeti

Başlık	Detay
Problem Türü	Çok Sınıflı Görüntü Sınıflandırma (6 sınıf)
Veri Seti	Kaggle Chess Pieces (~2000 görüntü)
Model Mimarisi	MobileNetV2 + Custom Classification Head
Yöntem	Transfer Learning (Feature Extraction + Fine-Tuning)
Veri Artırma	Rotation, Shift, Zoom, Horizontal Flip
Optimizör	Adam (lr=1e-3 → 1e-5)
Loss Fonksiyonu	Sparse Categorical Crossentropy
Test Accuracy	%85.53
En İyi Sınıf	Knight (At) — %95.7
En Zor Sınıf	Queen (Vezir) — %71.1 (Bishop ile karışıyor)
Programlama Dili	Python 3.12
Kütüphaneler	TensorFlow / Keras, OpenCV, scikit-learn, Pandas, Matplotlib, Seaborn